Base de référence pour les invertébrés et algues marines (CRABS)

Oct 29, 2026

Construction de bases de référence à partir de BOLD et de NCBI GenBank, basé sur CRABS v1.14.0, reproductible et documenté selon les principes FAIR. Les noms de phylum sont harmonisés selon Adl *et al.* (2019).

Objectif

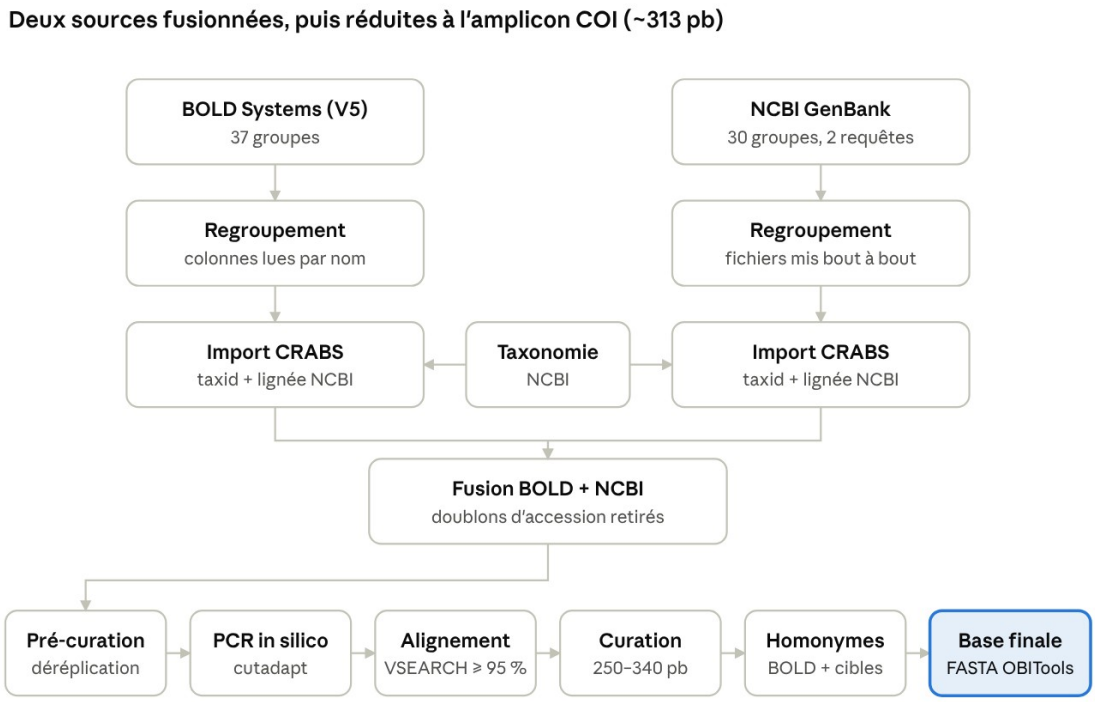
L'objectif est de disposer de bases de référence locales pour assigner taxonomiquement, avec OBITools, les séquences obtenues en métabarcoding sur les quatre marqueurs du projet. Chaque base couvre les organismes que ses amorces amplifient :

- **COI** (~313 pb) : invertébrés marins et algues marines.
- **18S** (~550 pb, 450–900 pb selon le groupe) : invertébrés marins et algues, plus tous les autres eucaryotes via SILVA ; une variante, 18S forward (150 pb), sert aux lectures forward seules.
- **16S** (180–480 pb selon le phylum, médiane 290 pb) : invertébrés marins.
- **rbcL** (331 pb) : algues marines et herbiers.

Les groupes que les amorces amplifient sans être visés sont inclus quand c'est possible (les algues pour le COI, tous les eucaryotes pour le 18S) : sans eux, une lecture de ces organismes serait assignée de force au groupe ciblé le plus proche. Oublié d'y mettre *H.sapiens*.

Le COI sert de modèle : la chaîne de traitement est décrite ci-dessous pour lui, et les autres bases la reprennent avec leurs propres amorces, groupes et filtres.

Vue d'ensemble



pipeline crabs_coi.sh · 2 sources, 15 étapes

BOLD et NCBI sont traités séparément jusqu'à l'import, où chaque séquence reçoit sa lignée NCBI ; les deux sources sont ensuite fusionnées et suivent la même chaîne jusqu'à la base finale.

Sources et groupes taxonomiques

Les séquences proviennent de deux bases publiques, téléchargées groupe par groupe ; la lignée taxonomique de chaque séquence est reconstruite avec la taxonomie NCBI.

Source	Accès	Groupes téléchargés
BOLD Systems	Portail V5, requête `tax:<groupe>`	35 groupes d'invertébrés + Rhodophyta, Ochrophyta (environ 1,1 million de séquences)
NCBI GenBank	Entrez, base nucleotide : requête COI (200–50 000 pb, mitogénomes complets inclus) et requête des séquences mitochondriales non annotées	27 groupes d'invertébrés + Rhodophyta, Phaeophyceae, Bacillariophyta
NCBI Taxonomy	taxdump + nucl_gb.accession2taxid	Lignées de toutes les séquences

« Invertébrés marins » n'étant pas un taxon, j'ai retenu les groupes à dominante marine : éponges, cnidaires, cténophores, mollusques, annélides, échinodermes, ascidies, nématodes, crustacés, pycnogonides, etc. Les insectes, arachnides et myriapodes, surtout terrestres et très nombreux dans BOLD, sont exclus.

BOLD et NCBI ne nomment pas toujours les groupes de la même façon, d'où deux listes. Par exemple, BOLD range les diatomées et les algues brunes sous Ochrophyta, et découpe les crustacés en classes (Malacostraca, Copepoda…). La requête NCBI exacte est :

```
"<groupe>"[Organism] AND (COI[Gene] OR CO1[Gene] OR COX1[Gene] OR COXI[Gene] OR "cytochrome c oxidase subunit I"[All Fields] OR "cytochrome c oxidase subunit 1"[All Fields] OR "cytochrome oxidase subunit 1"[All Fields] OR "cytochrome oxidase subunit I"[All Fields]) AND 200:50000[SLEN]
```

La limite de 50 000 pb permet de garder les mitogénomes complets, qui contiennent le COI : ceux des algues rouges et brunes font 25 à 40 kb. Une seconde requête par groupe récupère les séquences mitochondriales sans annotation de gène, que la première ignore (par exemple « UNVERIFIED: B*eania erecta* isolate … mitochondrion sequence », issues de genome skimming) :

```
"<groupe>"[Organism] AND mitochondrion[filter] AND (UNVERIFIED[Title] OR genome[Title] OR "mitochondrion sequence"[Title] OR "mitochondrial sequence"[Title]) AND 200:50000[SLEN]
```

Les doublons entre les deux requêtes sont retirés à la fusion ; la PCR in silico extrait ensuite le fragment COI de ces séquences.

Étapes du traitement

Le script enchaîne seize étapes ; chacune produit un fichier vérifié avant de passer à la suivante.

1. **Taxonomie NCBI**

Téléchargement de `names.dmp`, `nodes.dmp` et `nucl_gb.accession2taxid` (une seule fois, réutilisés par les autres marqueurs). Depuis 2025, NCBI nomme le rang supérieur « domain » au lieu de « superkingdom » : le script le détecte et adapte les rangs, sinon ce rang resterait vide pour toutes les séquences.

2. **Téléchargement BOLD et NCBI**

Groupe par groupe, avec pour NCBI une seconde requête pour les séquences mitochondriales non annotées. Chaque fichier est contrôlé : une page d'erreur HTML renvoyée par un serveur surchargé est détectée, supprimée et retéléchargée (jusqu'à 4 tentatives, pauses croissantes).

3. **Regroupement par source.**

Les fichiers NCBI sont mis bout à bout. BOLD envoie ses données par pages de 10 000 enregistrements dont le nombre de colonnes varie sans nouvel en-tête : chaque ligne est donc lue par nom de colonne et, si sa largeur diffère, réalignée d'après la position de la séquence ADN. Seuls l'identifiant (`record_id`), le taxon (`species`, sinon `identification`) et la séquence (`nuc`, en majuscules) sont gardés. Cette lecture fait passer BOLD de 203 280 à 1 104 786 séquences, tous marqueurs confondus : le portail BOLD V5 livre tous les marqueurs d'un groupe, et ceux qui ne sont pas du COI sont écartés à la PCR in silico.

4. **Import au format CRABS (un import par source)**

Attribution d'un taxid et d'une lignée NCBI à 7 rangs (domain à species).

5. **Fusion des deux sources**

Les doublons de numéro d'accession sont retirés.

6. **Sauvetage des lignées**

Une séquence dont le nom d'espèce est inconnu de la taxonomie NCBI (nom récent, provisoire ou propre à BOLD) reçoit la lignée de son genre, si ce genre existe sans ambiguïté chez les eucaryotes. Sans cela, CRABS l'importe sans lignée et les filtres la suppriment. Si le nom de genre existe aussi dans un autre règne, la lignée peut être celle de l'homonyme (voir “homonymies de genre”).

7. **Pré-curation sur les séquences entières, pour alléger l'alignement**

Déréplication `unique_species`, retrait des séquences environnementales (non associées à un specimen) et de celles qui ne sont pas identifiées au moins au genre.

8. **PCR in silico (cutadapt)**

Extraction de la région entre les amorces, 4 mésappariements tolérés, option `--relaxed`. jgHCO2198 étant l'amorce universelle de barcoding (reverse), son site manque dans la plupart des barcodes déposés ; une seule amorce suffit alors.

9. **Alignement global (VSEARCH)**

Les séquences déposées sans sites d'amorces sont alignées sur les amplicons de l'étape 8 ; celles à ≥ 95 % d'identité sur ≥ 95 % de longueur sont gardées, réduites à la région de l'amplicon. C'est l'étape la plus longue (environ 15 h) ; sur la version 1.4 elle a récupéré 23 569 séquences (0,9 %), dont 682 espèces absentes du reste de la base. Elle peut être désactivée (`USE_PGA=false`).

10. **Recoupe des amplicons trop longs (version 1.7.3)**

La version 1.7.2 retirait 54 372 amplicons de plus de 340 pb, dont environ 40 000 hors insectes (Mollusca ~15 000, Arthropoda ~11 000, Platyhelminthes ~5 000). Ce sont des barcodes de Folmer et des gènes COI complets où jgHCO2198 n'a pas été reconnu (avec --relaxed, l'amplicon court alors jusqu'au bout de la séquence), et des mitogénomes où cutadapt a coupé à un faux site d'amorce en amont (il prend le premier site acceptable, pas le meilleur). Un amplicon trop long est recoupé aux sites d'amorce trouvés à l'intérieur, sinon à la région qui s'aligne (VSEARCH, identité ≥ 85 %) sur toute la longueur d'un amplicon de longueur normale. Les changements sont notés dans logs/09_long_trimmed.tsv. Résultat (26 octobre) : sur 2 719 512 amplicons, 66 548 dépassent 340 pb, dont 53 690 hors taxons exclus ; 6 sont recoupés aux sites internes, 49 001 par alignement, 4 683 restent trop longs et sont retirés. Base finale : 364 602 séquences et 77 086 taxons, de 250 à 340 pb, médiane 313 pb. Contrôle taxonomique : 3 séquences signalées, Caledoniella, gardées par décision manuelle. Les indexations lancées sur le cluster avec les versions précédentes de la base ont été arrêtées dès que le problème a été repéré ; les anciennes versions ont été supprimées et toutes les bases (COI, 16S, 18S, 18S forward, rbcL) ont été renvoyées et indexées de zéro, au propre, le 26 octobre.

11. **Curation finale**

Nouvelle déréplication, filtres de longueur et de bases ambiguës (au plus 1 N). Les amplicons de 280–340 pb sont gardés ; ceux de 250–279 pb, un peu plus courts que le fragment, ne sont gardés que pour les espèces qui n'ont aucun amplicon complet (environ 9 500 espèces gagnées, dont *Antarctonemertes unilineata*).

12. **Contrôle de traduction**

Un amplicon n'est gardé que si l'un de ses trois cadres de lecture ne contient aucun codon stop (TAA, TAG ; TGA code le tryptophane dans les codes mitochondriaux des groupes ciblés). Ce contrôle écarte pseudogènes, erreurs de séquençage et décalages du cadre de lecture, y compris parmi les séquences « UNVERIFIED » ; les séquences retirées sont listées dans `logs/10_translation_removed.tsv`.

13. **Correction des homonymes de genre**

La lignée de chaque séquence est comparée au phylum donné par BOLD et aux groupes ciblés ; une lignée prise à un genre homonyme d'un autre règne ou phylum est remplacée par celle du bon genre, ou la séquence est retirée (voir Homonymies de genre). Cette étape passe avant l'exclusion des arthropodes terrestres, pour qu'un insecte rangé sous une plante homonyme soit exclu une fois corrigé.

14. **Exclusion des arthropodes terrestres**

Insecta, Collembola, Protura, Diplura, Arachnida, Chilopoda, Diplopoda, Pauropoda, Symphyla, Onychophora, à n'importe quel rang de la lignée. NCBI range insectes et crustacés ensemble (Pancrustacea), et des séquences d'insectes sont parfois mal classées dans d'autres groupes.

15. **Rang minimal**

Seules les références nommées au moins au genre sont gardées.

16. **Harmonisation des phyla et export.**

Les noms de phylum suivent Adl *et al.* (2019) : les diatomées (Bacillariophyta) sont rangées dans Ochrophyta, les dinoflagellés dans Dinoflagellata, et le phylum est déduit de la classe quand NCBI n'en donne pas (algues brunes et autres classes d'Ochrophyta, dinoflagellés). Les phyla Metazoa et Rhodophyta restent ceux de NCBI. La base est ensuite exportée en FASTA à en-têtes OBITools, en table TSV et au format CRABS, avec ses métadonnées.

Les séquences pour lesquelles la PCR in silico et l'alignement échouent sont écartées. Les figures sont produites ensuite par un script R séparé (voir plus bas).

Paramètres

Tous les paramètres sont regroupés en tête du script et enregistrés à chaque exécution dans `metadata/parameters.tsv`.

Étape	Paramètre	Valeur
PCR in silico	Mésappariements par amorce	4

Étape	Paramètre	Valeur
PCR in silico	Une seule amorce suffit (`--relaxed`)	oui
Alignement global	Activé (`USE_PGA`)	oui
Alignement global	Identité minimale	0,95
Alignement global	Couverture minimale	95 %
Alignement global	Longueur max. des séquences alignées	10 000 pb
Curation	Longueur de l'amplicon	280–340 pb
Curation	Amplicons courts (`MIN_LEN_RESCUE`)	250–279 pb, seulement pour les espèces sans amplicon complet
Curation	Bases ambiguës (N)	au plus 1 (`--maximum-n 2` : CRABS retire les amplicons à 2 N ou plus)
Curation	Contrôle de traduction	codons stop TAA et TAG
Curation	Rang minimal d'identification (`MIN_ID_RANK`)	genre (espèce ou famille possibles)
Curation	Rangs manquants tolérés au-dessus du genre	1 (`--rank-na 3` déduit automatiquement)
Curation	Déréplication	`unique_species` (toutes les séquences uniques par espèce)
Curation	Séquences environnementales	retirées
Curation	Taxons exclus	arthropodes terrestres
Taxonomie	Rangs	domain, phylum, class, order, family, genus, species
Taxonomie	phyla renommés (`PHYLUM_RENAME`)	Bacillariophyta et Heterokontophyta → Ochrophyta ; Myzozoa et Dinophyta → Dinoflagellata
Taxonomie	Phylum déduit de la classe (`CLASS_TO_PHYLUM`)	Phaeophyceae et 18 autres classes → Ochrophyta ; Dinophyceae → Dinoflagellata
Téléchargement	Séquences mitochondriales non annotées (`NCBI_EXTRA_QUERY`)	téléchargées

Étape	Paramètre	Valeur
Téléchargement	Tentatives par groupe	4 (pauses de 60 s, doublées)
Téléchargement	Pause entre groupes BOLD	10 s
Taxonomie	Correction des homonymes de genre (TAXONOMY_FIX, TARGET_CHECK)	oui : phylum BOLD, puis groupes ciblés + Ichthyostraca, Mystacocarida (TARGET_EXTRA) ; décisions manuelles dans taxonomy_manual_crabs.tsv (TAXONOMY_MANUAL)

Reprise automatique et traçabilité (FAIR)

Le script peut être relancé à tout moment sans refaire ce qui est déjà fait. Une étape est sautée si son fichier existe, s'il est plus récent que ses entrées et s'il a été produit avec les mêmes paramètres (une signature est enregistrée pour chaque étape). Si une entrée ou un paramètre change, l'étape et toutes les suivantes sont refaites ; les téléchargements valides sont toujours conservés.

CRABS s'arrêtant sans code d'erreur quand une étape échoue, le script vérifie après chaque étape que le fichier attendu existe, et s'arrête sinon avec un message explicite.

À chaque exécution, le script génère dans `metadata/` :

- les **sources** : pour chaque groupe, la base, la date de téléchargement, le nombre d'enregistrements et la requête exacte
- les **paramètres** utilisés
- les **versions des logiciels** (script, CRABS, cutadapt, VSEARCH, BLAST+, Python, système)
- le **nombre de séquences à chaque étape**
- les **sommes de contrôle SHA-256** des fichiers résultats (sorte d'empreinte numérique unique)
- un **README** de la base et un fichier **JSON** reprenant toutes ces informations, lisible par machine

Chaque étape a aussi son journal dans `logs/`. La base est ainsi décrite, citable et reconstructible à l'identique.

Fichiers produits

La base à utiliser pour l'assignation est `results/COI_marine_invertebrates_algae.fasta`.

Fichier	Contenu
`results/COI_marine_invertebrates_algae.fasta`	Base finale ; en-têtes `taxid=…; scientific_name=…; lineage=…;` lisibles par OBITools

Fichier	Contenu
`results/COI_marine_invertebrates_algae.tsv`	Même contenu en table, avec noms de colonnes
`results/COI_marine_invertebrates_algae.txt`	Format CRABS, réutilisable par toutes les fonctions CRABS
`results/insilico_pcr_raw.fasta`	Sortie brute de la PCR in silico, avant alignement et filtres
`metadata/README.md`, `run_metadata.json`	Description de la base et métadonnées complètes
`metadata/sources.tsv`, `parameters.tsv`, `versions.tsv`, `counts.tsv`	Sources, paramètres, logiciels, effectifs par étape
`metadata/taxonomy_harmonisation.tsv`	Chaque changement de phylum (Adl *et al*. 2019) et le nombre de séquences concernées
`metadata/checksums_sha256.txt`	Sommes de contrôle des résultats
`steps/01_merged.txt` … `09_min_rank.txt`	Fichiers intermédiaires numérotés (dont `01b_lineage_rescued.txt`, `07b_length_rescued.txt`, `07c_translation_checked.txt`)
`raw/`, `imported/`, `taxo/`	Données téléchargées, imports CRABS, taxonomie NCBI
`logs/`	Journal de chaque étape, dont `10_translation_removed.tsv` (séquences retirées par le contrôle de traduction)
`figures/`	Figures du script R (PNG 300 dpi et PDF), leurs données dans `figures/data/`
`logs/10_taxonomy_fix.tsv`	Chaque lignée corrigée, gardée ou retirée par la correction des homonymes, avec la raison, l'ancienne et la nouvelle lignée
`taxonomy_manual_crabs.tsv`	Décisions manuelles sur les homonymes (facultatif, écrit à la main à partir du modèle du script de contrôle)
`checks/`	Résultats de crabs_check_taxonomy.sh : un dossier par contrôle et l'historique des contrôles

Figures et diagnostic

Les figures sont produites par un script R séparé, `crabs_figures.R`, placé dans le dossier `CRABS/`. Les couleurs suivent la palette viridis, lisible par les daltoniens (dédicasse à Étienne) et en niveaux de gris.

Figure	Contenu
fig01	Nombre de séquences à chaque étape du pipeline
fig02	Espèces et séquences par phylum (équivalent de `--diversity-figure`)
fig03	Part de BOLD et de NCBI dans les séquences retenues, par phylum
fig04	Longueurs après la PCR in silico, avec la fenêtre gardée
fig05	Longueurs finales par phylum (équivalent de `--amplicon-length-figure`)
fig06	Nombre de séquences de référence par espèce
fig07	Complétude des lignées à chaque rang
fig08	Enregistrements téléchargés de BOLD et de NCBI, par phylum (mêmes phyla que la figure 2)
fig09	Bases trouvées à chaque position des amorces (équivalent de `--amplification-efficiency-figure`)
fig10	Mésappariements aux amorces par phylum et par position
fig11	Complétude pour les espèces d'intérêt (équivalent de `--completeness-table`), si une liste `species_of_interest.txt` est fournie
fig12	Résolution taxonomique : part des espèces dont les séquences ne sont partagées avec aucune autre espèce, par phylum
fig13	Espèces et séquences des taxons fixés et pionniers (Porifera, Cnidaria, Bryozoa, Annelida, Nematoda, Platyhelminthes, Rhodophyta, Ochrophyta), par source

Les figures 2, 3, 8 et 13 sont triées par nombre de séquences, « Other phyla » toujours en dernier. Le script R applique la même harmonisation des phyla (Adl *et al.* 2019) que le script CRABS. BOLD et NCBI n'ayant pas été interrogés avec les mêmes noms de groupes (par exemple Malacostraca et Copepoda dans BOLD, Crustacea dans NCBI), la figure 8 rattache chaque groupe téléchargé à son phylum par une table de correspondance fixe, enregistrée dans `figures/data/group_taxonomy.tsv`.

Depuis sa version 2.5, `crabs_figures.R` lancé sans argument produit les figures de toutes les bases trouvées (`crabs_coi`, `crabs_16s`, `crabs_18s`, `crabs_18s_fwd`, `crabs_rbcl`), chacune dans son dossier `figures/`. Le marqueur est reconnu d'après `metadata/parameters.tsv` ou le nom du dossier. Pour le rbcL, la figure 13 montre les grands groupes d'algues (diatomées, algues brunes, autres

Ochrophyta, algues rouges, algues vertes, haptophytes, cryptophytes, herbiers), et la figure 8 rattache chaque groupe téléchargé à son phylum. Une figure qui échoue est sautée avec un message, sans bloquer les autres.

Un second script, `crabs_trace_species.sh`, suit une liste d'espèces (par exemple celles détéctées par OBITools v4 avec les précédentes banques de références) à travers chaque étape et indique où chacune disparaît : jamais téléchargée, nom inconnu de NCBI, perdue à la PCR, au filtre, etc. Il signale aussi les autres noms sous lesquels le genre figure dans la base, et l'origine des insectes restants.

Bases des autres marqueurs

Les bases 18S, 16S et rbcL reprennent la même chaîne que le COI, avec leurs propres amorces, groupes et filtres. Chaque base a son propre script et son dossier, à côté de `crabs_coi/`. Elles réutilisent la taxonomie NCBI et les fichiers BOLD déjà téléchargés pour le COI : un fichier BOLD contient tous les marqueurs d'un groupe, et seuls ceux du bon marqueur sont gardés. Une quatrième base, 18S forward, est tirée des séquences de la base 18S.

Amorces des quatre marqueurs (séquences 5' → 3', codes IUPAC ; longueur de l'amplicon sans les amorces) :

Marqueur	Sens	Amorce	Séquence 5'→3'	Amplicon	Référence
COI	sens	mlCOIintF	`GGWACWGGWTGAACWGTWTAYCCYCC`	~313 pb	Leray et al. 2013, *Frontiers in Zoology* 10: 34 (doi)
COI	antisens	jgHCO2198	`TANACYTCNGGRTGNCCRAARAAYCA`	~313 pb	Geller et al. 2013, *Molecular Ecology Resources* 13: 851–861 (doi)
18S	sens	18Smk1F	`CTGGTGCCAGCAGCCGCGGYAA`	~550 pb	Machida & Knowlton 2012, *PLoS ONE* 7: e46180 (doi)
18S	antisens	18Smk2R	`TCCGTCAATTYCTTTAAGTT`	~550 pb	Machida & Knowlton 2012, *PLoS ONE* 7:

Marqueur	Sens	Amorce	Séquence 5'→3'	Amplicon	Référence
					e46180 (doi)
16S	sens	Sarri_F	`AYAAGACGAGAAGACCC`	180–480 pb	Sarri et al. 2014, *Food Control* 43: 35–41 (doi)
16S	antisens	16Sbr-H	`CCGGTCTGAACTCAGATCACGT`	180–480 pb	Palumbi et al. 1991, *The Simple Fool's Guide to PCR*, version 2.0, University of Hawaii
rbcL	sens	rbcL-646F	`ATGCGTTGGAGAGARCGTTTC`	331 pb	Kelly et al. 2018, Environment Agency, rapport SC140024/R
rbcL	antisens	rbcL-998R	`GATCACCTTCTAATTTACCWACAACTG`	331 pb	Kelly et al. 2018, Environment Agency, rapport SC140024/R

Base (script)	Amorces	Fragment gardé	Sources	Particularités
18S V4-V5 (`crabs_18S.sh` 1.5)	18Smk1F / 18Smk2R (Machida & Knowlton 2012)	450–900 pb (médiane ~554 pb)	SILVA SSU 138.2, NCBI, BOLD	SILVA apporte tous les eucaryotes, pour qu'une lecture non ciblée ne soit pas forcée sur un invertébré ; bactéries et archées retirées ; références identifiées au moins au genre ; homonymes contrôlés aussi d'après la lignée SILVA
16S (`crabs_16S.sh`	Sarri_F (Sarri et al. 2014) /	180–480 pb (médiane	NCBI, BOLD	Séquences mitochondriales non annotées ajoutées, comme pour le COI ; PCR in silico stricte (deux

Base (script)	Amorces	Fragment gardé	Sources	Particularités
1.4)	16Sbr-H (Palumbi 1991)	290 pb)		amorces) et fenêtre de longueur large (voir ci-dessous) ; pas de contrôle de traduction (ARN)
rbcL (`crabs_rbcL.sh` 1.4)	rbcL-646F / rbcL-998R (Kelly et al. 2018)	310–360 pb (331 pb)	NCBI, BOLD	Algues marines et herbiers (Zosteraceae, Posidoniaceae, Cymodoceaceae) ; contrôle de traduction avec le code plastidial (stops TAA, TAG, TGA) ; correction des homonymes de genre ; recoupe des amplicons trop longs (sites internes, sinon alignement)
18S forward (`crabs_18S_fwd.sh` 1.3)	18Smk1F seule	150 pb après l'amorce	Séquences nettoyées de la base 18S	Pour les lectures forward seules (voir ci-dessous) ; construite dans le dossier `crabs_18s/`, avec des fichiers préfixés par son nom pour ne rien écraser du 18S ; même correction taxonomique que le 18S

La base 18S inclut SILVA pour éviter les fausses assignations. Les amorces 18Smk1F et 18Smk2R visent des régions très conservées du 18S : elles amplifient aussi les protistes (ciliés, dinoflagellés, foraminifères…), les champignons, les algues et les vertébrés, nombreux sur des ARMS. NCBI et BOLD ne sont interrogés que pour les groupes ciblés ; sans autre source, une lecture de cilié serait assignée à l'invertébré le plus proche. SILVA SSU Ref NR99 (version 138.2) apporte tous les eucaryotes, en séquences contrôlées, alignées et non redondantes à 99 % : une telle lecture trouve alors son vrai groupe. C'est le même principe que les algues dans la base COI. En contrepartie, la base et son index sont plus gros ; `USE_SILVA=false` donne une base limitée aux groupes ciblés, au risque de surestimer la diversité des invertébrés.

Les amorces rbcL ont été conçues pour les diatomées : les autres algues sont gardées pour que leurs lectures ne soient pas forcées sur une diatomée, mais elles peuvent moins bien s'amplifier.

16S : longueur de l'amplicon et PCR in silico (version 1.3)

La première base 16S (versions 1.1 et 1.2) gardait les amplicons de 200 à 300 pb et acceptait les séquences n'ayant qu'un site d'amorce (`--relaxed`). La figure 4 montrait des longueurs très étalées, de 130 à plus de 450 pb, en deux bosses. Deux causes ont été identifiées en refaisant la PCR in silico sans `--relaxed` :

- **La longueur de cette région du 16S varie fortement entre phyla.**

Sur les 30 266 amplicons à deux sites d'amorce, la médiane est de 290 pb (10 % sous 210 pb, 10 % au-dessus de 322 pb). La valeur de ~250 pb, typique des mollusques, ne vaut pas pour tous les invertébrés. La fenêtre de 200 à 300 pb retirait la plupart des échinodermes, des cnidaires et des éponges, et la moitié des arthropodes. *Ce qui me laisse penser que dans la réalité, la PCR loupe pas mal de taxons donc?*

- **Le mode `--relaxed` créait de faux amplicons.**

80 % des amplicons (122 587 sur 152 853) n'avaient qu'un site d'amorce ; CRABS garde alors la séquence jusqu'à son extrémité. Leur longueur dépendait de la façon dont la séquence avait été déposée : trop courte si elle commence après le site de Sarri_F, trop longue si 16Sbr-H n'est pas reconnu dans un gène complet. Pour le COI, ce mode convient, car les barcodes de Folmer s'arrêtent au site de jgHCO2198 ; pour le 16S, non.

Phylum	Amplicons à deux amorces	Longueur médiane	Avec la fenêtre 200–300 pb
Nematoda	168	209 pb	gardés
Platyhelminthes	193	221 pb	gardés
Mollusca	12 532	261 pb	gardés
Bryozoa	790	262 pb	gardés
Annelida	3 702	270 pb	gardés
Nemertea	365	292 pb	en partie perdus
Arthropoda	10 065	300 pb	moitié perdue
Chordata	73	331 pb	perdus
Echinodermata	1 359	347 pb	perdus
Hemichordata	42	363 pb	perdus
Cnidaria	436	405 pb	perdus
Porifera	345	456 pb	perdus

La version 1.3 de `crabs_16S.sh` exige donc les deux sites d'amorce (`RELAXED=false`) et garde les amplicons de 180 à 480 pb (longueur attendue 290 pb pour les figures). Les séquences déposées sans les deux sites sont récupérées par l'alignement global, qui les coupe exactement à la région de l'amplicon. La base est reconstruite à partir de la PCR in silico ; l'alignement global traite alors environ 150 000 séquences au lieu de 28 100.

Version 1.4 : amplicons trop longs. Une référence attendue : *Antarcticaetos bubeccata* (OK245238, mitogénome de 15 230 pb), manquait dans la base finale alors qu'une OTU lui est assignée à 100 %. Son mitogénome porte deux sites proches de Sarri_F : l'un à 4 mésappariements en position 11 126, l'autre (le bon) à 3 mésappariements en position 13 249. Cutadapt coupe au premier site acceptable depuis le début, pas au meilleur : l'« amplicon » faisait 2 373 pb au lieu de 250 pb et était retiré par le filtre de longueur maximale, avec 1 111 autres amplicons. La version 1.4 ajoute une étape (`09_trim_long`) après l'alignement global : un amplicon de plus de 480 pb est recoupé aux sites d'amorce trouvés à l'intérieur (au plus 4 mésappariements), en gardant la coupe qui tombe dans la fenêtre avec le moins de mésappariements. Sur la base 16S, 918 amplicons ont été recoupés (dont OK245238, retrouvé à 250 pb) et 219, sans site interne, restent retirés (`logs/09_long_trimmed.tsv`). La base 16S version 1.4 compte 34 880 séquences pour 13 118 taxons, de 180 à 480 pb (médiane 287 pb).

18S : fenêtre de longueur, amplicons trop longs et ARN d'organites (version 1.5)

Le filtre final de la base 18S version 1.4 retirait 7 091 amplicons trop longs (10 %) et 3 837 trop courts. Trois causes ont été identifiées :

- **La fenêtre de 500 à 680 pb était trop étroite.**

La région fait environ 550 pb pour la plupart des groupes, mais elle est plus longue chez les Platyhelminthes (médiane 639 pb, 90 % sous 707 pb), les Cnidaria (90 % sous 683 pb), les Porifera et les Tardigrada (90 % sous 640 pb) et une partie des Arthropoda (90 % sous 836 pb), et plus courte chez les Ciliophora (10 % sous 475 pb). Entre 681 et 800 pb, 1 783 amplicons d'arthropodes, 1 195 de Platyhelminthes et 709 de Cnidaires étaient perdus. La fenêtre passe à 450–900 pb.

- **Des amplicons trop longs venaient d'un faux site d'amorce.**

Comme pour le 16S : même étape de recoupe (`09_trim_long`).

- **Des ARN d'organites étaient pris pour du 18S.**

SILVA SSU contient aussi les 16S de chloroplastes et de mitochondries, que SILVA classe chez Bacteria mais que NCBI range sous la plante ou l'algue hôte. Ils formaient un groupe d'amplicons d'environ 370 pb chez Streptophyta, Rhodophyta, Chlorophyta et Euglenozoa : parmi les amplicons de moins de 450 pb retrouvés dans SILVA, 2 855 étaient classés chez Bacteria et 543 chez Eukaryota. L'étape de correction taxonomique retire désormais toute séquence que SILVA classe chez Bacteria ou Archaea (« organelle rRNA » dans `logs/10_taxonomy_fix.tsv`).

Vérification des taxons attendus (18S)

Un script, `crabs_check_taxa.sh`, vérifie qu'une liste de taxons de n'importe quel rang est présente dans toutes les bases d'un dossier. Il cherche chaque taxon dans le nom d'espèce et dans toute la lignée

NCBI de chaque séquence, y compris les rangs que la base ne garde pas (sous-classe *Hexacorallia*, par exemple). Quand un taxon manque, il indique la dernière étape où il était encore présent. Les résultats sont enregistrés dans `<base>/checks/taxa_check_<date>_<heure>.tsv`.

Appliqué aux 16 taxons assignés aux OTU 18S (lectures forward avec BOLD, et lectures appariées), il donne :

Taxon	Base 18S (séquences / espèces)	Base 18S forward (séquences / espèces)
Clathria	21 / 13	26 / 20
Calcarea	99 / 75	96 / 80
Actiniidae	106 / 69	106 / 71
Acanthogorgia	16 / 9	10 / 8
Gersemia	1 / 1	1 / 1
Mitrocomella frigida	absente : aucune séquence publique	absente
Chaperiopsis	5 / 5	5 / 5
Nematoflustra flagellata	1 / 1	1 / 1
Protocirrineris	absent : aucune séquence 18S téléchargée	absent
Eurycope	56 / 24	42 / 24
Discosea	292 / 181	321 / 205
Mesodinium	3 / 2	3 / 2
Glabratellidae	absents : chloroplastes retirés (voir ci-dessous)	absents
Axinella	19 / 15	23 / 18
Hexacorallia	1 151 / 712	1 006 / 746
Gastropoda	1 989 / 1 622	2 631 / 2 292

Les seules séquences de Glabratellidae téléchargées sont celles de *Planoglabratella opercularis* (KP792453 à KP792479), longues d'environ 375 pb et classées par SILVA chez Cyanobacteriota. Ce sont des 16S de chloroplaste : ce foraminifère est kleptoplaste et garde les chloroplastes des diatomées qu'il ingère. Il n'existe donc aucune vraie séquence 18S de Glabratellidae, et leur retrait est correct. Une OTU assignée à Glabratellidae avec une autre base serait très probablement un 16S de chloroplaste de diatomée, et non un foraminifère (à confirmer par sa longueur, environ 375 pb).

Le fragment 18S (~574 pb) est plus long que ce que couvre un séquençage MiSeq v2 2 × 250 : beaucoup de lectures sont perdues quand les lectures sens et antisens sont appariées. Les lectures forward seules ne lisent que le début du fragment. Comparées à des références complètes, trois fois plus longues, leur identité est sous-estimée. La base 18S forward ne garde donc que les 150 pb qui suivent 18Smk1F : PCR in silico avec la seule amorce sens (cutadapt, 4 mésappariements), puis récupération par alignement (VSEARCH, ≥ 95 %) des séquences déposées sans le site d'amorce, gardées seulement si toute la région est couverte. Les lectures forward nettoyées font de 34 à 191 pb (médiane 108 pb), et non 250 pb : l'amorce (~20 pb) est retirée et la fin des lectures (de moindre qualité), est coupée. Une OTU plus courte que la fenêtre ne peut pas être comparée et n'est pas assignée : 150 pb garde 36 OTU sur 123, soit 56 % des lectures (aucune à 250 pb, une seule à 191 pb). C'est un compromis : une fenêtre plus longue distingue mieux les espèces mais garde moins d'OTU ; une fenêtre de 100 à 120 pb en garderait davantage, avec plus de séquences partagées entre espèces. Les lectures doivent être coupées à la même longueur (`obigrep -l 150` puis `obiannotate --cut 1:150`). Sur 150 pb, plusieurs espèces partagent parfois la même séquence : obitag assigne alors à leur ancêtre commun. Version 1.3 (26 octobre) : 67 746 séquences et 41 959 taxons, de 145 à 155 pb (médiane 150 pb) ; 6 227 séquences sont partagées par plusieurs taxons. La correction taxonomique a retiré 2 978 ARNr d'organites (lignée SILVA Bacteria : 1 881 Cyanobacteria, 998 Pseudomonadota, 46 Bacteroidota, 25 Actinomycetota, 18 Bacillota, 5 Verrucomicrobiota, 5 Spirochaetota) et 352 séquences dont le phylum diffère de SILVA sans homonyme connu ; 46 homonymes ont été corrigés (37 d'après SILVA, 9 d'après BOLD).

Homonymies de genre

Certaines séquences reçoivent la lignée d'un genre homonyme appartenant à un autre règne ou à un autre phylum. Le problème a été repéré sur la base rbcL, puis mesuré sur le COI : 1 687 séquences touchées (0,47 %). Une même étape de correction, ajoutée aux quatre scripts, ramène ce nombre à 15 cas tranchés à la main.

Les figures de la base rbcL montraient des Arthropoda, des Chordata, des Apicomplexa, des Platyhelminthes et des Cnidaria. Or aucun animal n'a de rbcL, et les requêtes NCBI et BOLD ne demandaient que des algues et des herbiers. La liste de ces séquences a montré 21 noms d'algues, presque tous issus de BOLD, chacun rangé sous un animal du même nom de genre :

Genre (algue)	Animal homonyme	Lignée reçue
Trentepohlia (algue verte)	tipule	Arthropoda
Lobophora, *Elachista* (algues brunes)	papillons	Arthropoda
Heterococcus (xanthophycée)	cochenille	Arthropoda
Lessonia (laminaire)	oiseau	Chordata
Alaria (algue brune)	trématode	Platyhelminthes
Nitzschia (diatomée)	monogène	Platyhelminthes
Myrionema (algue brune)	hydraire	Cnidaria

Genre (algue)	Animal homonyme	Lignée reçue
Urospora (algue verte)	grégarine	Apicomplexa

Quand un enregistrement n'a pas de taxid NCBI utilisable (enregistrement BOLD, espèce inconnue de NCBI), CRABS lui attribue sa lignée d'après son nom ; le sauvetage des lignées (étape 6) fait de même à partir du genre. Si ce nom de genre existe aussi dans un autre règne, et que NCBI ne connaît que l'homonyme ou le choisit, la séquence change de phylum.

Les quatre scripts ont la même étape `10_taxonomy_fix.` Elle passe après le contrôle de traduction et avant l'exclusion des taxons. Pour chaque séquence, elle vérifie deux choses :

- Pour une séquence BOLD, le phylum donné par BOLD dans les fichiers d'origine doit être celui de la lignée NCBI. Pour une séquence SILVA (18S), même chose avec le premier nom de sa lignée SILVA qui est un phylum NCBI : CRABS trouve le taxid d'une séquence SILVA par son accession GenBank, sinon par son nom, et pour un nom homonyme il ne retient qu'un des genres, au hasard.
- La lignée NCBI doit remonter à l'un des groupes ciblés : les groupes téléchargés, plus Ichthyostraca (branchioures et pentastomides) et Mystacocarida, que NCBI range hors des classes de crustés demandées. Ce contrôle est désactivé pour le 18S, où SILVA apporte tous les eucaryotes exprès.

Une lignée fausse est remplacée par celle du genre du même nom qui convient, d'abord dans le phylum BOLD, sinon dans les groupes ciblés, quand il n'y en a qu'un. Sinon la séquence est retirée, sauf si BOLD semble se tromper et que la lignée NCBI reste dans les groupes ciblés : elle est alors gardée. Un nom qui est en fait un taxon supérieur (« Ctenophora », « Oligochaeta ») est retiré. Les vrais insectes sont laissés à l'étape suivante, qui les exclut. Chaque changement est noté dans `logs/10_taxonomy_fix.tsv`, avec la raison, l'ancienne et la nouvelle lignée.

Pour le 18S, le désaccord avec SILVA révèle surtout un autre problème que l'homonymie. SILVA classe chaque séquence d'après la séquence elle-même (placement phylogénétique), alors que NCBI la range sous l'organisme déclaré, souvent l'hôte. Le contrôle de la base 18S (version 1.3) a signalé 501 séquences sur 53 857 (0,93 %, 208 genres) sans genre de rechange, par exemple des 18S de ciliés déposés sous *Gammarus*, *Melita* ou *Asellus* (épibiontes), de plathelminthes sous *Daphnia galeata* et *Bosmina longirostris* (parasites), ou d'arthropodes sous *Aspergillus* et *Puccinia* (contaminations). Ces références assigneraient des lectures au mauvais organisme : la version 1.4 de `crabs_18S.sh` les retire (`UNRESOLVED_MISMATCH=remove`). Les champignons font exception : NCBI et SILVA ne découpent pas les phyla fongiques de la même façon (*Basidiobolus* : Basidiobolomycota ou Zoopagomycota), donc deux phyla du règne Fungi ne comptent pas comme un désaccord (`SAME_KINGDOM_OK="Fungi"`), dans le script comme dans le contrôle.

Décisions manuelles

Les cas que la règle ne peut pas trancher sont décidés à la main dans un fichier facultatif, `taxonomy_manual_crabs.tsv`, placé dans le dossier de la base. Il a quatre colonnes : taxon (un genre

ou un `seq_id`), action (`keep` ou `remove`), raison et date. Une décision sur un genre ne touche que ses séquences signalées : les autres séquences de ce genre restent. L'étape lit ce fichier en premier ; les décisions sont citées dans `metadata/parameters.tsv` et le README de la base, et modifier le fichier refait l'étape à la relance suivante.

Script de contrôle

`crabs_check_taxonomy.sh`, contrôle une base ou toutes, sans les modifier. Il fait les mêmes contrôles que l'étape de correction (phylum BOLD, phylum de la lignée SILVA pour le 18S, groupes ciblés), liste les genres NCBI de chaque nom signalé et propose la lignée correcte quand un seul genre convient. Il ne remplace jamais un contrôle précédent :

Fichier	Contenu
`checks/taxonomy_check_<date>_<heure>/`	Un dossier par lancement : résumé daté, table par séquence, table par genre, journal
`checks/ taxonomy_check_history_crabs.tsv`	Une ligne ajoutée à chaque lancement : date, empreinte SHA-256 de la base, effectifs, dossier des résultats
`taxonomy_manual_template_crabs.tsv` (dans le dossier du lancement)	Les genres à trancher à la main, avec les éléments pour décider ; il suffit de remplir `action` et de reporter les lignes dans `taxonomy_manual_crabs.tsv`

Le déroulé est donc : script de la base, puis contrôle ; s'il reste des cas, remplir le modèle et relancer le script de la base (quelques minutes). S'il n'y a rien à trancher, le contrôle l'indique et aucun fichier n'est nécessaire.

Résultat sur la base COI

Contrôle	Base	Séquences signalées	Genres
23 oct. 2026, 17 h 17	version 1.6 (358 205 séquences)	1 687 (0,47 %)	94
23 oct. 2026, 17 h 41	version 1.7.1 (358 156 séquences)	15	5

Avant correction, les phyla attribués à tort étaient surtout Streptophyta (1 038 séquences), Ascomycota (141), Ochrophyta (139), Chytridiomycota (108), Arthropoda (107) et Cyanobacteriota (79). Les plus touchés : *Fridericia* (219, oligochètes rangés sous une plante), *Macrostylis* (211, isopodes, plante), *Siphonaria* (108, gastéropodes, champignon chytride), *Nais* (105, oligochètes, ascomycète), *Lunella* (96, gastéropodes, diatomée) et *Cephalothrix* (79, némertes, cyanobactérie). Des insectes rangés sous des homonymes échappaient aussi à l'exclusion (*Isotoma*, collembole, 45 séquences ; *Xyleborus*, *Pieris*, *Nomia*).

Les 15 cas restants, où BOLD et NCBI ne s'accordent pas sans genre de rechange, ont été tranchés dans `taxonomy_manual_crabs.tsv` (version 1.7.2) :

Genre	Séquences	BOLD	Base	Décision
Caledoniella	3	Porifera	Mollusca	Gardée : gastéropode parasite de stomatopodes, BOLD se trompe
Roperia	8	Mollusca	diatomée	Retirée : murex (*Roperia poulsoni*) rangé sous une diatomée homonyme
Trichia	1	Mollusca	crabe	Retirée : escargot terrestre rangé sous un crabe homonyme
Anoplostrongylus	2	Nematoda	cestode	Retirée : nématode parasite de mammifères, hors cible
Chondrus	1	Mollusca	algue rouge	Retirée par prudence : origine de la séquence incertaine

Assignation sur le cluster (OBITools4)

Les bases sont indexées (`obirefidx`) puis utilisées pour assigner les OTU (`obitag`, table par `obicsv`) sur le cluster IFB, avec OBITools 4.4.0, un script SLURM par marqueur (`crabs_obitag_slurm_<marqueur>.sh`, dossier `CRABS_v1/`). Le script convertit les en-têtes CRABS au format OBITools4, met à jour les taxids fusionnés et retire ceux inconnus de la taxonomie NCBI ; l'index n'est refait que si la base change. Les résultats sont dans `CRABS_v1/obitools4/` :

`<OTU>_assignments_crabs_<base>.csv` (taxon assigné et `obitag_bestid` par OTU) et `<OTU>_taxo_crabs_<base>.fasta`.

Base	Références	Partition, cœurs	Indexation	OTU assignées
rbcL	13 737	fast, 32	1 h 18	187
16S	34 880	fast, 32	8 h 22	52
18S forward (150 pb)	67 746	fast, 128	~3 h 30 estimées	36 sur 123 (OTU ≥ 150 pb, coupées à 150 pb)
18S V4-V5	59 079	fast, 128	~15 h	
COI	364 602	long, 128	en cours depuis le 28 octobre, ~7 jours estimés	

Aucune référence n'a été retirée pour taxid inconnu ; un taxid fusionné a été mis à jour dans chaque base 18S.

Les 19 OTU 18S issues des lectures appariées (`DDU_18S_swarm_clust.fasta`, 365 à 371 pb) ne sont assignées qu'aux Eukaryota, avec une identité de 0,57 à 0,59. Ce ne sont pas des 18S : elles commencent par `TACG…GCGTTATCCGGAATTATTGGGCGTAAAG`, le début de la région V4 de l'ARNr 16S bactérien. Le fragment 18S eucaryote (~574 pb) est trop long pour que les lectures 2 × 250 se chevauchent ; seuls des amplicons bactériens hors cible, plus courts (~370 pb), ont pu être appariés. La base 18S n'est pas en cause : l'assignation des eucaryotes repose sur les lectures forward seules (base 18S forward).

Avec la base 18S forward, 23 des 36 OTU forward d'au moins 150 pb ont une référence identique ou presque (identité 0,95 à 1), surtout des bryozoaires, souvent assignés seulement au phylum ou à l'ordre : sur 150 pb, le début du V4 est presque identique d'une famille à l'autre. Les 13 autres (identité 0,55 à 0,74) ont été examinées une à une : seq22 et seq123 commencent comme un 18S puis sautent à une région située ~400 pb plus loin (délétions de PCR, à écarter) ; seq84, très riche en A et T, n'a pas l'air d'un 18S nucléaire ; seq51 et cinq variantes (seq24, seq40, seq73, seq79, seq89 ; plus de 700 lectures dans 3T, 4B et 8B) forment un même eucaryote au 18S très divergent, dont seul un tiers s'aligne sur GenBank (BLASTn, couverture 35 %) : un vrai taxon absent des bases, à garder comme « eucaryote non assigné ». VSEARCH (uchime_denovo, avec les abondances) ne détecte aucune chimère parmi les 123 OTU forward.

Points d'attention

- **Limite de téléchargement BOLD.**

BOLD limite la quantité de données téléchargeables sur une période donnée ; au-delà, il répond par des erreurs 503 ou 403. Le script cesse alors d'interroger BOLD, affiche un avertissement et construit la base avec les données disponibles. Il faut attendre quelques heures à une journée, puis relancer : seuls les groupes manquants seront téléchargés.

- **Ce que montrent les sites web n'est pas toujours téléchargeable.**

Le moteur d'identification BOLD inclut des enregistrements privés ou non publiés, qui ne peuvent pas être téléchargés dans la base.

- **Noms provisoires.**

Certaines séquences GenBank portent un nom provisoire (par exemple « Ballia sp. 1callitricha » pour *Ballia callitricha*). Elles sont gardées sous ce nom .

- **Taxonomie NCBI pour toutes les séquences.**

CRABS reconstruit les lignées avec la taxonomie NCBI, y compris pour les séquences issues de BOLD ; seuls les noms de phylum sont ensuite harmonisés selon Adl *et al.* (2019). Pour l'assignation avec OBITools, il faut utiliser une taxonomie NCBI **de la même époque que celle de la base** : avec une taxonomie plus ancienne, les références à taxid récent sont ignorées (6 810 références lors du premier test, car version datant de mai 2026).

- **Références identifiées au genre.**

Elles étendent la couverture taxonomique, mais avec obi`tag` (assignation au plus petit rang commun des meilleures correspondances), une référence au genre aussi proche qu'une référence à l'espèce fait remonter l'assignation au genre.

- **Bornes de longueur.**

Les bornes 280–340 pb encadrent l'amplicon attendu (~313 pb) ; elles sont à vérifier sur les figures 4 et 5. Les références courtes (250–279 pb) ne couvrent pas toute la lecture : avec une assignation par alignement global, elles peuvent ne pas atteindre le seuil d'identité de l'espèce.

- **Groupes absents de la base.**

Les organismes non inclus (poissons, insectes, autres eucaryotes) peuvent être amplifiés par ces amorces ; leurs lectures risquent d'être assignées au groupe présent le plus proche. Un seuil de similarité strict est donc nécessaire lors de l'assignation, ou alors généré plusieurs banques, en incluant certains taxons potentiellement présents (ex : *H.sapiens* et autres contaminants).

Références

- Jeunen G.-J. et al. (2022) CRABS – a software program to generate curated reference databases for metabarcoding sequencing data. *Molecular Ecology Resources*. doi:10.1111/1755-0998.13741
- Ratnasingham S. & Hebert P. D. N. (2007) BOLD: The Barcode of Life Data System. *Molecular Ecology Notes*. doi:10.1111/j.1471-8286.2007.01678.x
- NCBI GenBank et NCBI Taxonomy. ncbi.nlm.nih.gov
- Adl S. M. et al. (2019) Revisions to the classification, nomenclature, and diversity of eukaryotes. *Journal of Eukaryotic Microbiology* 66: 4–119. doi:10.1111/jeu.12691
- Leray M. et al. (2013) A new versatile primer set targeting a short fragment of the mitochondrial COI region. *Frontiers in Zoology*. doi:10.1186/1742-9994-10-34
- Geller J. et al. (2013) Redesign of PCR primers for mitochondrial cytochrome c oxidase subunit I for marine invertebrates. *Molecular Ecology Resources*. doi:10.1111/1755-0998.12138
- Machida R. J. & Knowlton N. (2012) PCR primers for metazoan nuclear 18S and 28S ribosomal DNA sequences. *PLoS ONE* 7: e46180. doi:10.1371/journal.pone.0046180
- Sarri C. et al. (2014) A new set of 16S rRNA universal primers for identification of animal species. *Food Control* 43: 35–41. doi:10.1016/j.foodcont.2014.02.036
- Palumbi S. R. et al. (1991) *The Simple Fool's Guide to PCR*, version 2.0. University of Hawaii, Honolulu.
- Kelly M. et al. (2018) A DNA based diatom metabarcoding approach for Water Framework Directive classification of rivers. Environment Agency, Bristol, rapport SC140024/R.
- Quast C. et al. (2013) The SILVA ribosomal RNA gene database project: improved data processing and web-based tools. *Nucleic Acids Research* 41: D590–D596. doi:10.1093/nar/gks1219
- Martin M. (2011) Cutadapt removes adapter sequences from high-throughput sequencing reads. *EMBnet.journal*. doi:10.14806/ej.17.1.200
- Rognes T. et al. (2016) VSEARCH: a versatile open source tool for metagenomics. *PeerJ*. doi:10.7717/peerj.2584

Les versions exactes des logiciels utilisés sont dans `metadata/versions.tsv`.